


Detecção de discurso de ódio em redes sociais

Grupo:

- Álvaro Brandão Neto - abn2
- Anselmo José Tavares Ferreira Junior - ajtfj
- Davi Sorrentino Brilhante - dsb6
- Thaylson Fernando da Silva -tfs5
- Robert Miller - rmls2



Contextualização

- Discurso de ódio nas redes sociais
- Impacto real - Transbordamento para violência física
- Volume incontável de mensagens, superando a capacidade humana




Soluções semelhantes

BRASIL #semódio

- pesquisadora Francielle Alves Vargas - ICMC (USP)
- Dataset HateBR - Primeiro DataSet brasileiro para detecção de discurso de ódio
- Social Stereotype Analysis (SSA) - usado para identificação de estereótipos em classificadores de IA

HateBERT e o RAL-E

- modelo base criado em 2021
- RAL-E dataset com mais 1,4 milhões de comentário do reddit
- atual benchmark para treinar ou medir eficácia de novas ferramentas



Desafios de implementação dessas soluções

- Moderação do conteúdo
- Critérios ocultos
- Transparência parcial
- Contexto conversacional
- Códigos e subterfúgios
- **Falta de definição universal**
- Viés cultural dos dados
- Uso de ironia e linguagem recuperada



Pipeline Geral - Detector Discurso de ódio




Preparação dos Dados




Preparação dos Dados

1. Limpeza + Tokenizacão




Preparação dos Dados

1. Limpeza + Tokenizacao




2. Divisao + Balanceamento



Arquitetura do Modelo



Arquitetura do Modelo




Treinamento




Treinamento


Loop de Treinamento



Learning Rate Schedule




Early Stopping



Pipeline de inferência



Pipeline de inferência



O Que Gostaríamos de Provar?

Hipótese do Trabalho

1 - Um Transformer pré-treinado em português consegue aprender padrões de discurso ofensivo.

2 - **Transfer learning:** O conhecimento adquirido durante o pré-treinamento pode ser reaproveitado por meio do fine-tuning.

3 - O modelo consegue generalizar para textos que não foram vistos durante o treinamento.



Conjunto de Dados Utilizado


Dataset Utilizado: ToLD-Br

- Textos em pt-br;
- Dados previamente rotulados (toxico/nao toxico e 0/1);
- split train/val/test (3 conjuntos) nativo ou automático;
- Adequado para treinamento supervisionado.

1	[INPUT TEXT] 'Você é um idiota'	→	[TARGET] Classe 1 : Ofensivo
2	[INPUT TEXT] 'Discordo do seu ponto'	→	[TARGET] Classe 0 : Neutro


[projetoemoreba/mteb told-br](https://projetoemoreba/mteb_told-br)

Descrição dos Experimentos



- limpar @menções (Twitter/X) e emojis;
- Tokenização dos textos;
- Treinamento supervisionado;
- Avaliação periódica durante o treinamento

Telemetria



- CrossEntropyLoss com pesos de classe;
- A generalização foi acompanhada por accuracy, precision, recall e F1 na validação.

A infraestrutura estabelecida e os próximos passo do pipeline




- [OK] Ingestão via datasets e Tokenização
- [OK] Setup do codificador BERTimbau
- [OK] Estratégia de Weighted Loss implementada
- [OK] Loop de Treino e Validação (checkpoints/ salvos)

[>_] Próximo: [Análise de Dados Finais e Pipeline de Inferência](#) →

Resultados

AVALIAÇÃO FINAL – CONJUNTO DE TESTE	
Val Loss:	0.4732
Accuracy:	75.76%
Precision:	0.6944
Recall:	0.8508
F1-Score:	0.7647



Análise dos Resultados e Novidades

- **Novidades Trazidas pelos Resultados:**

- O modelo não apenas detetou palavrões, mas compreendeu o contexto (ironia, linguagem informal, gírias da internet).
- A introdução da Weighted Loss (Perda Ponderada) inverteu a tendência do modelo de ignorar a classe minoritária.


- **O Desempenho Preditivo foi Satisfatório?**

- Sim. F1-Score estabilizado em 0.76 e Recall superior a 85%.
- Em bases de dados reais e ruidosas (como o ToLD-Br extraído do Twitter), valores acima de 0.75 são considerados um excelente ponto de partida (baseline) para soluções industriais.

Vs HateBERT - F1 Score

★ **Nosso Modelo**
→ **0.7647**


Dataset	Model	Macro F1 Pos. class - F1	
OffensEval 2019	BERT	.803±.006	.715±.009
	HateBERT	.809±.008	.723±.012
	<i>Best</i>	.829	.599
AbusEval	BERT	.727±.008	.552±.012
	HateBERT	.765±.006	.623±.010
	Caselli et al. (2020)	.716±.034	.531
HatEval	BERT	.480±.008	.633±.002
	HateBERT	.516±.007	.645±.001
	<i>Best</i>	.651	—



Vs Facebook - Acurácia

★ **Nosso Modelo**
→ 75,46%




AI now proactively
detects more of the
hate speech we remove
from Facebook.



Proactive detection
rate in Q3 2020



Análise dos Resultados e Novidades



Complexidade Computacional

Treino Vs Uso Real

- Fase de treino → intensiva, exigindo processamento pesado e placas de vídeo potentes
- Uso real → Classificação em milissegundos mesmo em um Hardware modesto

Justificativa Científica dos Resultados

- **Nossas Métricas de Pico (Época 2):**

- Acurácia: 77.00%
- F1-Score: 0.7569 (Métrica principal de controle)
- Recall: 82.82% (Alto poder de captura de ódio)
- Precision: 69.69%

- **Justificativas Técnicas de Deep Learning:**

- **A Força do BERTimbau:** Compreensão de sintaxe e semântica contextual superior a Regex e ML clássico.
- **O Papel da Weighted Loss:** O peso de classe configurado em 1.138 para discurso de ódio forçou o modelo a minimizar Falsos Negativos, resultando no excelente Recall de até 89.32% na primeira época.
- **Comportamento de Treino (Overfitting):** Na Época 3, a Train Loss caiu para 0.2978 enquanto a Val Loss subiu para 0.5010. Identificamos aqui o limite de generalização do modelo (overfitting inicial).

A Importância do Trabalho e Resolução do Problema

- **A Importância da Contribuição:**

- NLP de última geração aplicado ao Português (BERTimbau Cased).
- Substituição de filtros estáticos ineficientes por detecção de contexto e ironia.

- **O Problema foi de Fato Resolvido?**

- **Sim:** Como ferramenta de triagem automática em larga escala. Um modelo capaz de filtrar 83% do ódio de forma autónoma reduz drasticamente a carga sobre equipas humanas.
- **Não de forma isolada:** O discurso de ódio na internet é dinâmico (novas gírias surgem diariamente). A IA é uma camada crítica, mas o ciclo ideal de segurança ainda exige um moderador humano para casos limítrofes.

Próximos Passos e Trabalhos Futuros

- **1. Tratamento Avançado de Emojis:**
 - Em vez de apenas limpar e remover emojis no pré-processamento, traduzir emojis para texto semântico (ex: 😡 ==> "raiva") antes de enviar ao BERTimbau.
- **2. Otimização para Produção (Edge AI):**
 - Aplicação de Quantização (Quantization) e Destilação de Conhecimento (Knowledge Distillation) para reduzir o tamanho dos pesos do modelo, permitindo que ele corra localmente em dispositivos ou servidores baratos.

Detecção de discurso de ódio em redes sociais

Grupo:

- Álvaro Brandão Neto - abn2
- Anselmo José Tavares Ferreira Junior - ajtfj
- Davi Sorrentino Brilhante - dsb6
- Thaylson Fernando da Silva -tfs5
- Robert Miller - rmls2

